

# 07 · Playwright: páginas protegidas con login

A veces no hay API y la información vive en páginas que **exigen login**. En `tienda-virtual`, `proxy.ts` protege `/clientes`, `/ordenes`, `/carrito` y `/admin/*`: sin cookie de sesión válida, cualquier petición redirige (**HTTP 307**) a `/login`.

Con `Playwright` automatizamos un navegador real: abrimos `/login`, completamos el formulario (`admin@tienda.local` / `admin123`) y a partir de ahí el navegador conserva la cookie de sesión. Guardamos el `storage_state` para reutilizar la sesión sin volver a logear.

Requisitos: `tienda-virtual` corriendo y `playwright install chromium` ya ejecutado.

```
import csv
import os

import requests
from playwright.async_api import async_playwright

BASE = "http://localhost:3000"
USUARIO = "admin@tienda.local"
CLAVE = "admin123"
UA = "MineriaWeb-2026-2/1.0 (scraping con login)"

# Sin sesión, /ordenes redirige a /login (no seguimos el redirect para verlo):
r = requests.get(f"{BASE}/ordenes", allow_redirects=False, timeout=15)
print("GET /ordenes sin sesión ->", r.status_code, "->", r.headers.get("location"))
```

GET /ordenes sin sesión -> 307 -> /login?next=%2Fordenes

## Iniciar sesión con Playwright

Rellenamos el formulario por el atributo `name` de cada input y esperamos a que el `submit` nos deje en la home ya autenticados.

```
playwright = await async_playwright().start()
navegador = await playwright.chromium.launch(headless=True)
contexto = await navegador.new_context(user_agent=UA)
pagina = await contexto.new_page()

await pagina.goto(f"{BASE}/login", wait_until="networkidle")
await pagina.fill("input[name='email']", USUARIO)
await pagina.fill("input[name='password']", CLAVE)
await pagina.click("button[type='submit']")
await pagina.wait_for_url(f"{BASE}/", wait_until="networkidle")

print("URL tras el login:", pagina.url)
cookies = await contexto.cookies()
print("Cookies presentes:", [c["name"] for c in cookies])
```

URL tras el login: `http://localhost:3000/`  
Cookies presentes: `['tienda_session']`

## Guardar la sesión ( `storage_state` ) para reutilizarla

```
DATA_DIR = os.path.join(os.getcwd(), "..", "data")
os.makedirs(DATA_DIR, exist_ok=True)
STATE_PATH = os.path.join(DATA_DIR, "playwright_storage_state.json")
```

```
await contexto.storage_state(path=STATE_PATH)
print("Sesión guardada en", STATE_PATH)
```

Sesión guardada en /private/tmp/claude-501/-Users-ferris-pucp-mineria-mineria-web-2026-2/1b003788-da84-40ac-86e0-5b0e2134c0b1/scratchpad/build/repo/sesion-de-clase-03/notebooks/./data/playwright\_storage\_state.json

## Recorrer el listado paginado protegido `/ordenes`

Ya con sesión, `/ordenes` responde con HTML. Cada `<article data-orden-id>` puede traer reseñas de entrega embebidas como `<li data-tipo="post_compra">` con sus datos en atributos `data-*`. Paramos cuando el enlace **Siguiente** deja de ser un `<a>`.

```
resenas = []
numero_pagina = 1
while True:
    await pagina.goto(f"{BASE}/ordenes?page={numero_pagina}",
wait_until="networkidle")

    articulos = pagina.locator("article[data-orden-id]")
    n = await articulos.count()
    if n == 0:
        break

    for i in range(n):
        art = articulos.nth(i)
        orden_id = await art.get_attribute("data-orden-id")
        li = art.locator("li[data-tipo='post_compra']")
        for j in range(await li.count()):
            fila = li.nth(j)
            resenas.append({
                "id": await fila.get_attribute("data-comentario-id"),
                "orden_id": orden_id,
                "cliente_id": await fila.get_attribute("data-cliente-id"),
                "producto_id": await fila.get_attribute("data-producto-id"),
                "calificacion": await fila.get_attribute("data-calificacion"),
                "fecha": await fila.get_attribute("data-fecha"),
                "texto": (await fila.locator("
[itemprop='reviewBody']").inner_text()).strip(),
            })

        print(f"  página {numero_pagina:>2}: {n} órdenes")
        siguiente = pagina.locator('nav[aria-label="Paginacion"] a:has-
text("Siguiente")')
        if await siguiente.count() == 0:
            break
        numero_pagina += 1

print(f"\n{len(resenas)} reseñas de entrega en {numero_pagina} páginas de órdenes")
```

página 1: 10 órdenes  
página 2: 10 órdenes  
página 3: 10 órdenes  
página 4: 10 órdenes  
página 5: 10 órdenes  
página 6: 10 órdenes  
página 7: 10 órdenes  
página 8: 10 órdenes  
página 9: 10 órdenes  
página 10: 10 órdenes  
página 11: 10 órdenes  
página 12: 10 órdenes  
página 13: 10 órdenes  
página 14: 10 órdenes  
página 15: 10 órdenes  
página 16: 10 órdenes  
página 17: 10 órdenes  
página 18: 10 órdenes  
página 19: 10 órdenes  
página 20: 10 órdenes  
página 21: 10 órdenes  
página 22: 10 órdenes  
página 23: 10 órdenes  
página 24: 10 órdenes  
página 25: 10 órdenes  
página 26: 10 órdenes  
página 27: 10 órdenes  
página 28: 10 órdenes  
página 29: 10 órdenes  
página 30: 10 órdenes

110 reseñas de entrega en 30 páginas de órdenes

## Reutilizar la sesión guardada

Un contexto nuevo creado con `storage_state=STATE_PATH` entra directo a una página protegida ( `/admin/api-keys` ) sin volver a pasar por el login.

```
contexto2 = await navegador.new_context(storage_state=STATE_PATH, user_agent=UA)
pagina2 = await contexto2.new_page()
await pagina2.goto(f"{BASE}/admin/api-keys", wait_until="networkidle")

print("URL:", pagina2.url, "(no redirige a /login)")
print("Título de la página protegida:", await
pagina2.locator("h2").first.inner_text())
print("Filas en la tabla de API keys:", await pagina2.locator("table tbody
tr").count())

await contexto2.close()
```

URL: `http://localhost:3000/admin/api-keys` (no redirige a `/login`)

Título de la página protegida: API keys

Filas en la tabla de API keys: 1

Guardar en `data/playwright_resenas_entrega.csv`  
y cerrar el navegador

```
OUTPUT = os.path.join(DATA_DIR, "playwright_resenas_entrega.csv")
with open(OUTPUT, "w", newline="", encoding="utf-8") as f:
    writer = csv.DictWriter(f, fieldnames=list(resenas[0].keys()))
    writer.writeheader()
    writer.writerows(resenas)

await navegador.close()
await playwright.stop()

print(f"Guardadas {len(resenas)} filas en {OUTPUT}")
```

Guardadas 110 filas en /private/tmp/claude-501/-Users-ferris-pucp-mineria-mineria-web-2026-2/1b003788-da84-40ac-86e0-5b0e2134c0b1/scratchpad/build/repo/sesion-de-clase-03/notebooks/./data/playwright\_resenas\_entrega.csv

Resumen de la sesión: **a)** REST público (recurso, colección, paginación) -> **b)** REST con seguridad (API key, luego OAuth2) -> **c)** GraphQL (query simple, luego variables + anidado + OAuth) -> **d)** sin API, navegador real con login.