

02 · Normalización

Normalizar es uniformizar el texto para reducir variaciones que no aportan significado:

1. *lowercasing* → todo a minúsculas
2. eliminación de puntuación y símbolos
3. *stopwords removal* → quitar palabras muy comunes
4. *stemming* o *lematización* → llevar cada palabra a su forma base

Corpus: los **testimonios / comentarios** de clientes de la tienda-virtual, en `datos/comentarios.csv`.

```
from pathlib import Path

import pandas as pd

# El texto ya minado de la tienda-virtual está copiado en la carpeta datos/ de
# este mismo proyecto:
#   datos/resenas_entrega.csv   reseñas de entrega (post_compra)
#   datos/comentarios.csv      testimonios / comentarios de clientes
#   datos/productos.csv        catálogo con la descripción de cada producto
DATOS = Path("../datos")

def cargar(nombre, **kwargs):
    """Lee un CSV de la carpeta datos/ y lo devuelve como DataFrame."""
    ruta = DATOS / nombre
    if not ruta.exists():
        raise FileNotFoundError(f"No se encontró {ruta.resolve()}")
    print(f"Leyendo {ruta} ({ruta.stat().st_size / 1024:.1f} KB)")
    return pd.read_csv(ruta, **kwargs)
```

```
comentarios = cargar("comentarios.csv")
corpus = comentarios["texto"].dropna().astype(str).tolist()
print(f"{len(corpus)} comentarios")
comentarios[["calificacion", "texto"]].head(5)
```

Leyendo ../datos/comentarios.csv (22.4 KB)
135 comentarios

	calificacion	texto
0	5	El proceso de facturacion para empresa fue mas...
1	3	En general cumple lo que promete, ni mejor ni ...
2	4	Buena tienda en general, seguire comprando aqu...
3	3	El envio internacional tardo mas dias de los i...
4	3	El proceso de devolucion fue sencillo de inici...

Paso a paso sobre un comentario

```
import re

original = corpus[3]
print("0. original      :", original)

minuscula = original.lower()
print("1. minúsculas    :", minuscula)

sin_signos = re.sub(r"^[^\w\s]", " ", minuscula)
sin_signos = re.sub(r"\s+", " ", sin_signos).strip()
print("2. sin puntuación :", sin_signos)
```

0. original : El envío internacional tardo mas dias de los indicados originalmente.
1. minúsculas : el envío internacional tardo mas dias de los indicados originalmente.
2. sin puntuación : el envío internacional tardo mas dias de los indicados originalmente

Stopwords

NLTK trae una lista de *stopwords* en español. Quitarlas reduce el ruido, aunque en tareas de estilo o búsqueda exacta de frases conviene conservarlas.

```
import nltk

nltk.download("stopwords", quiet=True)
stop_es = set(nltk.corpus.stopwords.words("spanish"))
print(f"{len(stop_es)} stopwords en español. Ejemplos: {sorted(list(stop_es))[:15]}")

tokens = sin_signos.split()
sin_stop = [t for t in tokens if t not in stop_es]
quitadas = [t for t in tokens if t in stop_es]

print("\n3. sin stopwords      :", sin_stop)
print("   (se quitaron)       :", quitadas)
```

313 stopwords en español. Ejemplos: ['a', 'al', 'algo', 'algunas', 'algunos', 'ante', 'antes', 'como', 'con', 'contra', 'cual', 'cuando', 'de', 'del', 'desde']

3. sin stopwords : ['envío', 'internacional', 'tardo', 'mas', 'dias', 'indicados', 'originalmente']
 (se quitaron) : ['el', 'de', 'los']

Stemming (Snowball) vs Lematización (spaCy)

- **Stemming**: recorta la palabra a una *raíz* con reglas mecánicas. Rápido, pero la raíz puede no ser una palabra real (entrega → entreg).
- **Lematización**: devuelve el *lema* (forma de diccionario) usando contexto y categoría gramatical (entregados → entregar).

```

import spacy
from nltk.stem import SnowballStemmer

nlp = spacy.load("es_core_news_sm")
stemmer = SnowballStemmer("spanish")

palabras = ["llegó", "llegaron", "llegando", "entrega", "entregado", "entregaron",
            "rápido", "rápidamente", "comprando", "compré", "productos",
            "devolución"]

comparacion = pd.DataFrame(
    {
        "palabra": palabras,
        "stem (Snowball)": [stemmer.stem(p) for p in palabras],
        "lema (spaCy)": [nlp(p)[0].lemma_ for p in palabras],
    }
)
comparacion

```

	palabra	stem (Snowball)	lema (spaCy)
0	llegó	lleg	llegar
1	llegaron	lleg	llegar
2	llegando	lleg	llegar
3	entrega	entreg	entrega
4	entregado	entreg	entregado
5	entregaron	entreg	entregar
6	rápido	rap	rápido
7	rápidamente	rapid	rápidamente
8	comprando	compr	comprar
9	compré	compr	comprar
10	productos	product	producto
11	devolución	devolu	devolución

Pipeline de normalización completo

Combinamos todos los pasos en una función reutilizable. La usaremos también en los notebooks de Bag of Words, TF-IDF y minería de texto.

```

import re
import unicodedata

import nltk
import spacy

nlp = spacy.load("es_core_news_sm")
STOPWORDS = set(nltk.corpus.stopwords.words("spanish"))

```

```

def _limpiar(texto):
    # NFKC junta tildes combinantes sueltas; luego minúsculas y solo letras/espacios
    texto = unicodedata.normalize("NFKC", str(texto)).lower()
    return re.sub(r"^\w\s]", " ", texto)

def _lemas(doc):
    return [
        t.lemma_.lower()
        for t in doc
        if t.is_alpha and not t.is_stop and t.lemma_.lower() not in STOPWORDS and
len(t.lemma_) > 2
    ]

def normalizar(texto):
    """minúsculas -> sin signos -> sin stopwords -> lematizado. Devuelve un str."""
    return " ".join(_lemas(nlp(_limpiar(texto))))

def normalizar_muchos(textos):
    """Igual que normalizar() pero en lote con nlp.pipe (más rápido para un
corpus)."""
    return [" ".join(_lemas(doc)) for doc in nlp.pipe([_limpiar(t) for t in textos],
batch_size=64)]

```

```

muestra = pd.DataFrame(
    {
        "original": corpus[:6],
        "normalizado": normalizar_muchos(corpus[:6]),
    }
)
pd.set_option("display.max_colwidth", 90)
print(muestra)

```

```

original \
0          El proceso de facturacion para empresa fue mas simple de lo que
esperaba.
1  En general cumple lo que promete, ni mejor ni peor que otras tiendas de tecnologia
que...
2          Buena tienda en general, seguire comprando aqui mis proximos
equipos.
3          El envio internacional tardo mas dias de los indicados
originalmente.
4  El proceso de devolucion fue sencillo de iniciar aunque tomo unos dias en
confirmarse.
5  Muy buena atencion personalizada cuando pregunte por disponibilidad de un modelo
agotado.

```

```

                                normalizado
0          proceso facturacion empresa simple esperar
1      general cumplir prometer tienda tecnologia probar
2          tienda general seguire comprar proximo equipo
3          envio internacional tardo indicado originalmente
4      proceso devolucion sencillo iniciar tomo confirmar él
5  atencion personalizado pregunte disponibilidad modelo agotado

```

Siguiente: `03_ngram.ipynb` — antes de descartar el orden por completo (Bag of Words), veamos cómo los n-gramas capturan el contexto local.