

07 · Síntesis: las tres representaciones, lado a lado

Cierre de la sesión: la misma frase del corpus de trabajo, vectorizada con los tres enfoques vistos, y los criterios para elegir uno u otro fuera del salón de clase.

```
import numpy as np
from sentence_transformers import SentenceTransformer
from sklearn.feature_extraction.text import CountVectorizer, TfidfVectorizer

corpus = ["el gato duerme en el sofá", "el perro duerme en la alfombra", "el sismo sacudió la costa"]
frase = corpus[0]

bow = CountVectorizer(token_pattern=r"(?u)\b\w+\b").fit(corpus)
tfidf = TfidfVectorizer(token_pattern=r"(?u)\b\w+\b").fit(corpus)
sbert = SentenceTransformer("sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2")

vector_bow = bow.transform([frase]).toarray()[0]
vector_tfidf = tfidf.transform([frase]).toarray()[0]
vector_embedding = sbert.encode([frase])[0]

for nombre, vector in [("Bag-of-Words", vector_bow), ("TF-IDF", vector_tfidf), ("Embedding", vector_embedding)]:
    ceros = int((vector == 0).sum())
    print(f"{nombre:14} dim={len(vector):>4} ceros={ceros:>4} ({ceros/len(vector):.0%}) primeros valores: {np.round(vector[:6], 2)}")
```


```
/private/tmp/claude-501/-Users-ferris-pucp-mineria-mineria-web-2026-2/1b003788-da84-40ac-86e0-5b0e2134c0b1/scratchpad/venv311/lib/python3.11/site-packages/tqdm/auto.py:21: TqdmWarning: IPProgress not found. Please update jupyter and ipywidgets. See https://ipywidgets.readthedocs.io/en/stable/user_install.html
  from .autonotebook import tqdm as notebook_tqdm
Loading weights: 100%|██████████| 199/199 [00:00<00:00, 14520.99it/s]
Bag-of-Words    dim= 11   ceros= 6 (55%)   primeros valores: [0 0 1 2 1 1]
TF-IDF         dim= 11   ceros= 6 (55%)   primeros valores: [0.  0.  0.36 0.55 0.36 0.47]
Embedding      dim= 384  ceros= 0 (0%)    primeros valores: [ 0.48 -0.29 -0.13 0.18 0.07 0.3 ]
```

Representación	Dimensiones	Ceros	Qué determina los valores
Bag-of-Words	tamaño del vocabulario	casi todos	el conteo: cuántas veces aparece cada palabra
TF-IDF	tamaño del vocabulario	casi todos	el conteo, pesado por la rareza en el corpus
Embedding	fija (384 aquí; 300-1536 típico)	ninguno	un modelo entrenado sobre millones de oraciones

Registra apariciones sin ninguna noción de significado (BoW); distingue lo informativo de lo común, pero tampoco codifica significado (TF-IDF); codifica significado y contexto, a costa de no ser

interpretable (embedding). Un mismo texto, tres formas de convertirlo en números — la diferencia está en **qué determina esos valores**: el conteo, la estadística del corpus, o el modelo.

Criterios de selección



En producción casi nunca se elige uno solo: los buscadores combinan ambos enfoques (**búsqueda híbrida**) — primero recuperan candidatos con los dos métodos y luego reordenan solo los mejores con un modelo más caro y preciso. Así funcionó el buscador de `05_transformers-sbert.ipynb`.

Errores frecuentes en implementación

1. **Usar embeddings para todo.** Para buscar un código de factura, TF-IDF gana y cuesta mil veces menos cómputo.
2. **Promediar vectores sin pensar.** El promedio de un historial diverso —o dominado por una compra repetida, como se vio en `06_sistema-recomendacion.ipynb` — cae en un punto que no representa a nadie.
3. **Comparar cosenos entre modelos distintos.** 0.8 en un modelo y 0.8 en otro no significan lo mismo: los espacios vectoriales no son comparables entre sí.
4. **Olvidar el idioma del preentrenamiento.** Un modelo entrenado en inglés rinde mal en español técnico, aunque "funcione" en apariencia.
5. **No fijar una línea base.** Sin medir TF-IDF primero, no se sabe si el modelo caro aporta algo de verdad.

Glosario

Término	Definición
Vector disperso	Lista larga, casi toda de ceros. Bag-of-Words, TF-IDF.
Vector denso / embedding	Lista corta sin ceros, aprendida. Word2Vec, BERT.
Similitud coseno	Ángulo entre dos vectores. 1 = iguales, 0 = sin relación.
IDF	Dial que baja el peso de las palabras que salen en todos lados.
Negative sampling	Aproximación que evita recorrer todo el vocabulario en cada paso de Word2Vec.

Término	Definición
Self-attention	Cada palabra se recalcula mezclando a las demás según relevancia.
Contextual	El vector cambia según la frase. "Banco" ya no es uno solo.
Bi-encoder	Vectorizar por separado e indexar. Lo que hace viable buscar (SBERT).

Referencias

- Mikolov et al. (2013) — Word2Vec: la idea original.
- Levy & Goldberg (2014) — Word2Vec como factorización matricial.
- Pennington et al. (2014) — GloVe.
- Vaswani et al. (2017) — *Attention Is All You Need*.
- Devlin et al. (2019) — BERT.
- Reimers & Gurevych (2019) — Sentence-BERT.
- Jurafsky & Martin — *Speech and Language Processing*, cap. 6 (libre en línea).

Idea central de la sesión: vectorizar consiste en decidir qué relaciones queda en condiciones de detectar el modelo.