

Sesión de clase 06 · Ejercicio 1: búsqueda semántica en comentarios.csv

Hasta la sesión anterior sabíamos convertir un texto en un vector y comparar dos vectores con similitud coseno. Hoy resolvemos el siguiente problema: dada una consulta, encontrar los k textos más parecidos entre **miles o millones** de comentarios, sin depender de que compartan las mismas palabras.

Este notebook reproduce el **Ejercicio 1** de la clase: comparar una búsqueda con `WHERE texto LIKE '%lento%'` contra una búsqueda semántica con **ChromaDB**, sobre los 135 comentarios reales de la tienda del curso.

Datos: `data/comentarios.csv` — `cliente_id`, `cliente_ciudad`, `cliente_pais`, `calificacion`, `fecha`, `texto`.

Modelo de embeddings: `paraphrase-multilingual-MiniLM-L12-v2` (384 dimensiones, multilingüe, funciona en CPU).

```
import pandas as pd
import chromadb
from chromadb.utils import embedding_functions

pd.set_option("display.max_colwidth", 100)
```

1. Cargar

Leemos `comentarios.csv` con pandas. Nos interesan sobre todo `texto`, `calificacion` y `cliente_ciudad`.

```
comentarios = pd.read_csv("../data/comentarios.csv")
print(comentarios.shape)
comentarios[["cliente_id", "cliente_ciudad", "cliente_pais", "calificacion",
"texto"]]
```

(135, 8)

	cliente_id	cliente_ciudad	cliente_pais	calificacion	texto
0	35	Trujillo	Peru	5	El proceso de facturacion para empresa fue mas simple de lo que esperaba.
1	90	Cuenca	Ecuador	3	En general cumple lo que promete, ni mejor ni peor que otras tiendas de tecnologia que he probado.
2	31	Arequipa	Peru	4	Buena tienda en general, seguire comprando aqui mis proximos equipos.
3	27	Lima	Peru	3	El envio internacional tardo mas dias de los indicados originalmente.
4	84	Rosario	Argentina	3	El proceso de devolucion fue sencillo de iniciar aunque tomo unos dias en confirmarse.
...	...	...	...	...	...
130	4	Arequipa	Peru	1	Me cobraron el envio dos veces por un error del sistema y tuve que escribir tres correos distint...
131	5	Arequipa	Peru	4	El proceso de pago con tarjeta fue rapido, solo me hubiera gustado mas metodos de pago.
132	39	Chiclayo	Peru	4	Me parece justo el precio de envio comparado con otras tiendas de electronica.
133	1	Lima	Peru	5	La pagina es muy facil de navegar, encontre lo que buscaba en pocos minutos.
134	5	Arequipa	Peru	1	El sistema de puntos se reinicio sin explicacion despues de una actualizacion de la plataforma. ...

135 rows x 5 columns

¿Por qué no alcanza con LIKE ?

Necesidad: encontrar quejas sobre la lentitud del sitio web. La consulta SQL equivalente en pandas es `texto.str.contains("lento")`.

```
like_lento = comentarios[comentarios["texto"].str.contains("lento", case=False)]
print(f"{len(like_lento)} resultado(s) con LIKE '%lento%'")
like_lento[["calificacion", "texto"]]
```

3 resultado(s) con LIKE '%lento%'

	calificacion	texto
15	2	El proceso de cambio de producto por otro modelo fue mas lento de lo esperado.
41	3	El soporte responde en tiempos razonables, ni muy rapido ni muy lento comparado con otras tiendas.
117	1	La verificacion de identidad para mi primera compra tomo mas de tres dias habiles. Fue un proces...

Los comentarios que sí hablan de un sitio lento no siempre usan la palabra «lento»: dicen «tardan en cargar» o «podría cargar más rápido». `LIKE` no los encuentra porque busca la cadena exacta, no el significado. Y si ampliamos el patrón para intentar capturar variantes, aparecen falsos positivos:

```
like_lent = comentarios[comentarios["texto"].str.contains("lent", case=False)]
print(f"{len(like_lent)} resultado(s) con LIKE '%lent%'")
like_lent[["calificacion", "texto"]]
```

8 resultado(s) con LIKE '%lent%'

	calificacion	texto
15	2	El proceso de cambio de producto por otro modelo fue mas lento de lo esperado.
23	5	Excelente que muestren opiniones verificadas de compradores reales.
41	3	El soporte responde en tiempos razonables, ni muy rapido ni muy lento comparado con otras tiendas.
43	5	El servicio postventa fue excelente cuando necesite activar la garantia de mi laptop.
110	5	Excelente experiencia de principio a fin, desde la busqueda hasta la entrega del producto. Defin...
114	2	La pagina se puso lenta durante una oferta de temporada y perdi el producto que queria comprar. ...
117	1	La verificacion de identidad para mi primera compra tomo mas de tres dias habiles. Fue un proces...
123	5	Excelente variedad de marcas, encuentre opciones que no tenia en otras tiendas.

`%lent%` no solo trae los comentarios sobre lentitud: también atrapa «Excelente» porque la subcadena «lent» aparece ahí por coincidencia. Es el problema opuesto: ahora hay ruido. Esto es lo que motiva la búsqueda semántica.

2. Vectorizar y construir la colección de Chroma

Tres pasos: crear la colección (eligiendo el modelo de embedding y la métrica), agregar documentos (Chroma los vectoriza automáticamente) y consultar (la consulta se vectoriza con el mismo modelo).

Usamos `Client()` en memoria: alcanza para este ejercicio y se pierde al cerrar el proceso. La persistencia en disco (`PersistentClient`) se usa en el laboratorio.

```
ef = embedding_functions.SentenceTransformerEmbeddingFunction(
    model_name="paraphrase-multilingual-MiniLM-L12-v2"
)
```

```

cliente = chromadb.Client()
col_comentarios = cliente.get_or_create_collection(
    name="comentarios",
    embedding_function=ef,
    metadata={"hnsw:space": "cosine"},
)

col_comentarios.add(
    ids=comentarios["id"].astype(str).tolist(),
    documents=comentarios["texto"].tolist(),
    metadatas=comentarios[["cliente_ciudad", "cliente_pais",
"calificacion"]].to_dict("records"),
)

print(col_comentarios.count(), "comentarios indexados")

```

Loading weights: 100%  199/199 [00:00<00:00, 9454.12it/s]
135 comentarios indexados

3. Consultar

`query()` devuelve **distancias**, no similitudes: con métrica coseno, `similitud = 1 - distancia`.

```

def buscar(coleccion, consulta, n_results=5):
    res = coleccion.query(query_texts=[consulta], n_results=n_results)
    filas = []
    for doc, dist, meta in zip(res["documents"][0], res["distances"][0],
res["metadatas"][0]):
        filas.append({
            "similitud": round(1 - dist, 3),
            "ciudad": meta.get("cliente_ciudad"),
            "calificacion": meta.get("calificacion"),
            "texto": doc,
        })
    return pd.DataFrame(filas)

buscar(col_comentarios, "el sitio web es lento")

```

	similitud	ciudad	calificacion	texto
0	0.651	Chimbote	2	La pagina se puso lenta durante una oferta de temporada y perdi el producto que queria comprar. ...
1	0.548	Cusco	3	El sitio funciona bien en general aunque algunas paginas tardan un poco mas de lo esperado en ca...
2	0.446	Trujillo	2	El sitio no guarda bien las preferencias de idioma y cada vez que entro tengo que cambiarlo de n...
3	0.437	Montevideo	3	El diseno del sitio en modo oscuro tiene algunos textos dificiles de leer.
4	0.414	Chiclayo	3	El diseno del sitio es agradable pero en modo oscuro algunos textos son dificiles de leer. Peque...

Comparado con `LIKE '%lento%'` (3 resultados, ninguno relevante) y `LIKE '%lent%'` (8 resultados, la mitad ruido), la búsqueda semántica recupera los comentarios sobre lentitud del sitio

aunque usen palabras distintas («tardan en cargar», «podría cargar más rápido»).

```
buscar(col_comentarios, "tuve problemas para pagar con mi tarjeta")
```

	similitud	ciudad	calificacion	texto
0	0.647	Trujillo	2	Tuve problemas para aplicar un cupon de descuento durante el checkout.
1	0.621	Cusco	2	La factura electronica llego con datos incorrectos y tuve que pedir que la corrigieran.
2	0.614	Ciudad de Mexico	1	Me cobraron dos veces por error y tuve que esperar varios días para que me reembolsaran.
3	0.602	Arequipa	4	El proceso de pago con tarjeta fue rapido, solo me hubiera gustado mas metodos de pago.
4	0.580	Chiclayo	1	Cancele un pedido y el reembolso tardo mas de diez días habiles en aparecer en mi tarjeta. El so...

```
buscar(col_comentarios, "quiero devolver un producto")
```

	similitud	ciudad	calificacion	texto
0	0.537	Santiago	3	El sitio se cayo un momento durante una oferta especial, tuve que reintentar la compra.
1	0.515	Manta	5	El programa de puntos por compras es un buen incentivo para volver a comprar.
2	0.511	Santiago	4	Muy buena atencion cuando pregunte por la disponibilidad de un modelo agotado. Me avisaron apena...
3	0.493	Medellin	1	Compre un producto marcado como disponible y luego me avisaron que no habia stock.
4	0.483	Chimbote	2	El precio de un producto cambio de un día para otro sin ninguna explicacion clara. Senti que per...

4. Umbral de similitud

`query()` siempre devuelve `n_results` documentos, aunque ninguno tenga relación con la consulta. El umbral es la similitud mínima para aceptar un resultado; con embeddings multilingües suele estar entre 0.35 y 0.50, y se ajusta probando con datos propios.

```
UMBRAL = 0.45
```

```
def buscar_con_umbral(coleccion, consulta, umbral=UMBRAL, n_results=10):  
    df = buscar(coleccion, consulta, n_results=n_results)  
    return df[df["similitud"] >= umbral]  
  
print("Resultados que superan el umbral (0.45):")  
buscar_con_umbral(col_comentarios, "el sitio web es lento")
```

Resultados que superan el umbral (0.45):

	similitud	ciudad	calificacion	texto
0	0.651	Chimbote	2	La pagina se puso lenta durante una oferta de temporada y perdi el producto que queria comprar. ...
1	0.548	Cusco	3	El sitio funciona bien en general aunque algunas paginas tardan un poco mas de lo esperado en ca...

Con un umbral más bajo entran más resultados, algunos menos relacionados; con uno más alto se descartan resultados dudosos pero también algunos relevantes. No hay un valor «correcto» - se fija probando consultas reales y viendo dónde empieza a aparecer ruido.

Discusión: similitud semántica no es lo mismo que sentimiento

La consulta sobre pagos con tarjeta trae comentarios sobre el **tema** pago/tarjeta, sin importar si la experiencia fue buena o mala.

```
resultado_pago = buscar(col_comentarios, "tuve problemas para pagar con mi tarjeta",
n_results=5)
resultado_pago
```

	similitud	ciudad	calificacion	texto
0	0.647	Trujillo	2	Tuve problemas para aplicar un cupon de descuento durante el checkout.
1	0.621	Cusco	2	La factura electronica llego con datos incorrectos y tuve que pedir que la corrigieran.
2	0.614	Ciudad de Mexico	1	Me cobraron dos veces por error y tuve que esperar varios días para que me reembolsaran.
3	0.602	Arequipa	4	El proceso de pago con tarjeta fue rapido, solo me hubiera gustado mas metodos de pago.
4	0.580	Chiclayo	1	Cancele un pedido y el reembolso tardo mas de diez días hábiles en aparecer en mi tarjeta. El so...

Preguntas de discusión

- ¿Por qué puede aparecer en el top-5 un comentario con calificación alta (5★) sobre pagos, aunque la consulta hable de un *problema*? (La similitud semántica mide de qué tema habla el texto, no si la experiencia fue positiva o negativa.)
- ¿Qué umbral usarían para descartar resultados poco relacionados? Prueben distintos valores en `buscar_con_umbral` y observen dónde el resultado deja de tener sentido.
- ¿Qué pasaría si compararan la consulta contra `resenas_entrega.csv` en vez de `comentarios.csv`? (Se explora en el laboratorio.)