

Sesión de clase 06 · Ejercicio 2: clasificación de reseñas sin entrenamiento

Clasificación zero-shot: en vez de entrenar un clasificador con datos etiquetados, definimos cada categoría como una frase descriptiva, la vectorizamos igual que cualquier otro texto y asignamos a cada reseña la etiqueta cuyo vector sea más parecido al suyo. No hace falta ni un solo ejemplo etiquetado a mano.

Este notebook reproduce el **Ejercicio 2** de la clase sobre `data/resenas_entrega.csv` (110 reseñas de entrega, con su calificación de 1 a 5 estrellas).

```
import pandas as pd
import chromadb
from chromadb.utils import embedding_functions

pd.set_option("display.max_colwidth", 100)

resenas = pd.read_csv("../data/resenas_entrega.csv")
print(resenas.shape)
resenas[["cliente_id", "producto_id", "calificacion", "texto"]].head()
```

(110, 7)

	cliente_id	producto_id	calificacion	texto
0	73	10	1	Recibi el pedido incompleto, faltaba el cable de carga original del OnePlus 12 dentro de la caja...
1	88	89	3	El segundo cargador Belkin llego sin contratiempos, en el tiempo estimado y correctamente empackado.
2	28	45	5	La segunda Switch Lite que regale llego perfecta y justo a tiempo para el cumpleaños que la nece...
3	54	34	5	El segundo television TCL llego perfecto, bien empackado y sin ningun dano, muy distinto a la pri...
4	80	83	4	Me confirmaron por correo la garantia de un ano del cable Anker sin ningun problema.

1. Definir las etiquetas

Cinco categorías como frases descriptivas, no como palabras sueltas: el embedding representa mejor una frase completa que una sola palabra.

```
etiquetas = {
    "retraso": "Retraso en la entrega",
    "danado": "Producto dañado o defectuoso",
    "incompleto": "Pedido incompleto o accesorio equivocado",
    "buena_entrega": "Entrega rápida y en buen estado",
    "soporte": "Atención de soporte o posventa",
```

```
}  
etiquetas
```

```
{'retraso': 'Retraso en la entrega',  
 'danado': 'Producto dañado o defectuoso',  
 'incompleto': 'Pedido incompleto o accesorio equivocado',  
 'buena_entrega': 'Entrega rápida y en buen estado',  
 'soporte': 'Atención de soporte o posventa'}
```

2. Vectorizar etiquetas y reseñas

Guardamos las etiquetas como documentos de una colección de Chroma: así reutilizamos `query()` para encontrar, para cada reseña, la etiqueta más cercana (equivale a comparar la reseña contra cada una de las 5 frases y quedarnos con la de mayor similitud coseno).

```
ef = embedding_functions.SentenceTransformerEmbeddingFunction(  
    model_name="paraphrase-multilingual-MiniLM-L12-v2"  
)  
  
cliente = chromadb.Client()  
col_etiquetas = cliente.get_or_create_collection(  
    name="etiquetas_resenas",  
    embedding_function=ef,  
    metadata={"hnsw:space": "cosine"},  
)  
  
col_etiquetas.add(  
    ids=list(etiquetas.keys()),  
    documents=list(etiquetas.values()),  
)  
col_etiquetas.count()
```

Loading weights: 100%  199/199 [00:00<00:00, 8305.88it/s]

5

3. Clasificar cada reseña

Para cada texto de reseña, consultamos la colección de etiquetas con `n_results=1` : gana la etiqueta más parecida. Chroma acepta una lista de consultas en una sola llamada, así que clasificamos las 110 reseñas en un solo `query()` .

```
res = col_etiquetas.query(query_texts=resenas["texto"].tolist(), n_results=1)  
  
resenas = resenas.copy()  
resenas["etiqueta_id"] = [ids[0] for ids in res["ids"]]  
resenas["etiqueta"] = [docs[0] for docs in res["documents"]]  
resenas["similitud"] = [round(1 - dists[0], 3) for dists in res["distances"]]  
  
resenas[["calificacion", "etiqueta", "similitud", "texto"]].head(10)
```

	calificacion	etiqueta	similitud	texto
0	1	Pedido incompleto o accesorio equivocado	0.475	Recibi el pedido incompleto, faltaba el cable de carga original del OnePlus 12 dentro de la caja...
1	3	Entrega rápida y en buen estado	0.473	El segundo cargador Belkin llego sin contratiempos, en el tiempo estimado y correctamente empacado.
2	5	Entrega rápida y en buen estado	0.288	La segunda Switch Lite que regale llego perfecta y justo a tiempo para el cumpleaños que la neces...
3	5	Entrega rápida y en buen estado	0.208	El segundo television TCL llego perfecto, bien empacado y sin ningun dano, muy distinto a la pri...
4	4	Retraso en la entrega	0.249	Me confirmaron por correo la garantia de un ano del cable Anker sin ningun problema.
5	5	Entrega rápida y en buen estado	0.173	Los audifonos Bose se emparejaron al instante con mi telefono, cero complicaciones.
6	2	Retraso en la entrega	0.270	La instalacion de este segundo pedido de Family Hub se retraso otra vez, casi diez dias despues ...
7	3	Entrega rápida y en buen estado	0.455	La segunda camara instantanea llego completa y a tiempo, sin ningun inconveniente en esta ocasion.
8	5	Entrega rápida y en buen estado	0.326	Cambiar el color de mi Marshall por otro modelo fue un proceso rapido y sin costo.
9	4	Entrega rápida y en buen estado	0.203	El Amazfit se sincronizo sin problemas con la app apenas lo encendi.

```
ejemplo = resenas.iloc[0]
print("Reseña: ", ejemplo["texto"])
print("Etiqueta asignada:", ejemplo["etiqueta"], f"(similitud {ejemplo['similitud']})")
```

Reseña: Recibi el pedido incompleto, faltaba el cable de carga original del OnePlus 12 dentro de la caja. Tuve que esperar un envio adicional solo para recibir ese accesorio.

Etiqueta asignada: Pedido incompleto o accesorio equivocado (similitud 0.475)

4. Cruzar con la calificación (1–5★)

Si la clasificación captura bien el contenido de las reseñas, las categorías de problemas (retraso, dañado, incompleto) deberían concentrar las calificaciones bajas, y «entrega rápida y en buen estado» las calificaciones altas.

```
tabla = pd.crosstab(resenas["etiqueta"], resenas["calificacion"])
tabla
```

	calificacion	1	2	3	4	5
etiqueta						
Atención de soporte o posventa	0	0	0	1	0	
Entrega rápida y en buen estado	0	4	9	16	26	
Pedido incompleto o accesorio equivocado	8	4	9	3	1	
Producto dañado o defectuoso	1	2	1	2	4	
Retraso en la entrega	1	5	2	7	4	

```
resumen = (
    resenas.groupby("etiqueta")["calificacion"]
    .agg(n="count", calificacion_promedio="mean")
    .sort_values("calificacion_promedio")
    .round(2)
)
resumen
```

	n	calificacion_promedio
etiqueta		
Pedido incompleto o accesorio equivocado	25	2.40
Retraso en la entrega	19	3.42
Producto dañado o defectuoso	10	3.60
Atención de soporte o posventa	1	4.00
Entrega rápida y en buen estado	55	4.16

Discusión

- ¿Qué categoría concentra las calificaciones de 1★ y 2★? Revisen la tabla cruzada: ¿coincide con lo esperado (retraso, dañado, incompleto)?
- ¿Cómo cambia el resultado si reformulan alguna etiqueta? Por ejemplo, cambien "Producto dañado o defectuoso" por "El producto llegó roto" y vuelvan a ejecutar la celda de clasificación: ¿algunas reseñas cambian de categoría? ¿la similitud promedio sube o baja?
- Esta clasificación no usó ni un solo ejemplo etiquetado a mano: solo la descripción de cada categoría. ¿En qué casos esto sería insuficiente y haría falta un clasificador entrenado con ejemplos reales?

```
# Espacio para experimentar: reformulen una etiqueta y comparen resultados
# Usamos upsert() (no add()): si vuelven a ejecutar esta celda tras cambiar
# el texto de una etiqueta, add() ignoraría el id repetido y dejaría el
# embedding viejo sin actualizar. upsert() sí reemplaza el documento y
# vuelve a vectorizarlo.
etiquetas_v2 = dict(etiquetas)
etiquetas_v2["danado"] = "Todo mal"

col_etiquetas_v2 = cliente.get_or_create_collection(
    name="etiquetas_resenas_v2",
```

```

embedding_function=ef,
metadata={"hnsw:space": "cosine"},
)
col_etiquetas_v2.upsert(ids=list(etiquetas_v2.keys()),
documents=list(etiquetas_v2.values()))

res_v2 = col_etiquetas_v2.query(query_texts=resenas["texto"].tolist(), n_results=1)
etiqueta_v2 = pd.Series([docs[0] for docs in res_v2["documents"]],
index=resenas.index)

cambiaron = resenas["etiqueta"] != etiqueta_v2
print(f"{cambiaron.sum()} de {len(resenas)} reseñas cambiaron de categoría al reformular la etiqueta")
resenas.loc[cambiaron, ["texto", "etiqueta"]].assign(etiqueta_v2=etiqueta_v2[cambiaron])

```

10 de 110 reseñas cambiaron de categoría al reformular la etiqueta

	texto	etiqueta	etiqueta_v2
11	La segunda laptop HP que compre llego con la pantalla algo desalineada del chasis. Funciona bien...	Producto dañado o defectuoso	Pedido incompleto o accesorio equivocado
13	El Galaxy S24 Ultra ya venia con la mayoría del software actualizado desde fabrica.	Producto dañado o defectuoso	Retraso en la entrega
16	El soporte tardo en responder sobre un problema de bateria del Moto G84.	Producto dañado o defectuoso	Entrega rápida y en buen estado
22	El segundo Samsung The Frame que compre llego con un pixel muerto visible en la esquina superior...	Producto dañado o defectuoso	Pedido incompleto o accesorio equivocado
28	El equipo de soporte reemplazo rapido un cable defectuoso de mis audifonos Bose.	Producto dañado o defectuoso	Pedido incompleto o accesorio equivocado
33	El disco WD Blue llego bien protegido contra golpes con plastico de burbuja.	Producto dañado o defectuoso	Retraso en la entrega
62	Definitivamente el Galaxy S24 Ultra fue la mejor compra de tecnologia que hice este ano.	Producto dañado o defectuoso	Entrega rápida y en buen estado
84	Los Bose QuietComfort llegaron en caja resistente, se nota el cuidado en el empaque.	Producto dañado o defectuoso	Atención de soporte o posventa
100	El Redmi Note 13 Pro llego con la caja visiblemente aplastada y un golpe en una esquina de la pa...	Producto dañado o defectuoso	Pedido incompleto o accesorio equivocado
104	El robot Xiaomi X10+ llego a tiempo, aunque la caja venia algo maltratada por fuera.	Producto dañado o defectuoso	Pedido incompleto o accesorio equivocado